HANDS ON COM IA · 31/10/2026

Caqui Invest: atendimento que escala com confiança

O código decide, o LLM só redige.

Escopo · arquitetura · solução

Empresa, pessoas, dados e taxas do case são fictícios. Este documento é uma proposta de trabalho: nada aqui está construído ainda.

O PROBLEMA

Atender 2 milhões de clientes com no máximo 100 pessoas

A base vai de 400 mil para 2 milhões em 18 meses; o time só pode ir de 62 para 100.

Os números do case

- 48 mil contatos humanos por mês hoje, a R$ 31 cada e 12 min em média.
- Na conta linear, 2 milhões de clientes pediriam cerca de 310 atendentes. Com 100, perto de dois terços da demanda precisa ser evitada ou resolvida sem humano.
- O chatbot atual resolve 12%; 41% digitam "atendente" na primeira mensagem; satisfação 2,1 contra 4,3 do humano.
- Regras do SAC: humano das 8h às 20h, todos os dias; cliente não repete a demanda.

A tese

Uma porta de entrada confiável

- Tudo o que tem risco é decidido por **código determinístico e testado**: cálculos, roteamento, horário.
- O **LLM só redige**, a partir de fatos já verificados e de trechos da base de conhecimento.
- Um **validador** confere o texto; se o modelo errar ou cair, entra um template.
- A **ação** (responder, encaminhar, recusar) nunca é escolhida pelo modelo.
- Funciona com qualquer LLM, e também sem nenhum.

Por que esse caminho: as armadilhas do case são quase todas de **cálculo** (regras 1, 2, 3 e 12) ou de **roteamento** (regras 4 a 8, 10 e 11). Nada disso deve depender de um modelo acertar.

ESCOPO

O que o agente resolve, o que encaminha e o que fica de fora

Frente	Contatos/mês	Tratamento
Onde está meu dinheiro	27%	**Resolve sozinho**: cálculo de liquidação
Dúvida de produto	19%	**Resolve** com a base de conhecimento e cita o artigo
Rentabilidade e extrato	14%	**Resolve**: comparação líquida com a poupança
Impostos e documentos	9%	**Resolve**: IR regressivo e informe
Golpe, recomendação, vulnerável, reclamação	o restante	**Não automatiza.** Reconhece na hora e entrega ao humano certo, com protocolo e resumo

Os quatro motivos resolvidos somam cerca de **69%** dos contatos, perto dos dois terços que o case diz ser preciso evitar ou resolver sem humano. É o **teto**: a fração que o agente de fato resolve depende de premissas (taxa de resolução, recontato) que a SPEC vai estimar e conferir contra as 300 conversas de `conversas.csv`.

Dentro

- As 12 regras de negócio, todas
- As 6 regras gerais do case
- Chat do cliente e painel do atendente
- Persona configurável e LLM intercambiável

Fora

- Autenticação real e banco de dados
- Voz e WhatsApp
- IOF e feriados estaduais/municipais
- Qualquer ação que mexa em dinheiro
- Atendente humano real (o painel só mostra os casos)

REGRAS DE NEGÓCIO

As 12 regras do case: todas cobertas

#	Regra	Como é coberta
1	Liquidação	Calculadora com corte das 16h, calendário com feriados, D+1/D+2 dos fundos e 30 dias corridos do multimercado. Calculada, nunca lida da planilha (a coluna vem vazia de propósito).
2	IR regressivo	Faixas 180/181, 360/361 e 720/721. Incide só sobre o rendimento. LCI, LCA e poupança isentas.
3	Comparação com a poupança	Sempre líquido contra líquido, com as taxas de `taxas.json`.
4	Sem recomendação	Sinal próprio, inclusive "finge que é assessor". Explica conceitos e encaminha ao especialista.
5	Golpe	Prioridade máxima: interrompe antes de responder a pergunta original, atende 24h e trava a sessão em modo segurança.
6	Cliente vulnerável	Idade, confusão, terceiro pressionando ou resgate atípico: prioridade humana, que persiste na sessão.
7	Reclamação e cancelamento	Disponíveis em qualquer passo, com no máximo uma tentativa de retenção.
8	Sem doom loop	Máximo de 5 passos; após 2 respostas sem entender, oferece humano.
9	Não sabe, diz que não sabe	Busca com limiar de confiança e artigo mais recente (KB-006 em vez do antigo KB-007); abaixo do limiar, não inventa.
10	Dados pessoais	CPF mascarado em tela e log. O servidor só carrega o cliente da sessão: dado alheio não tem de onde sair.
11	Instrução escondida	Texto do cliente é dado em bloco delimitado; o LLM não tem ferramenta de leitura de dados.
12	Horário	Humano das 8h às 20h; fora disso, protocolo e prazo de retorno. Relógio injetável para testes e demo.

ARQUITETURA

Seis camadas, cada uma testável sozinha

Entender e decidir ficam separados de redigir. Só a camada 5 chama o modelo.

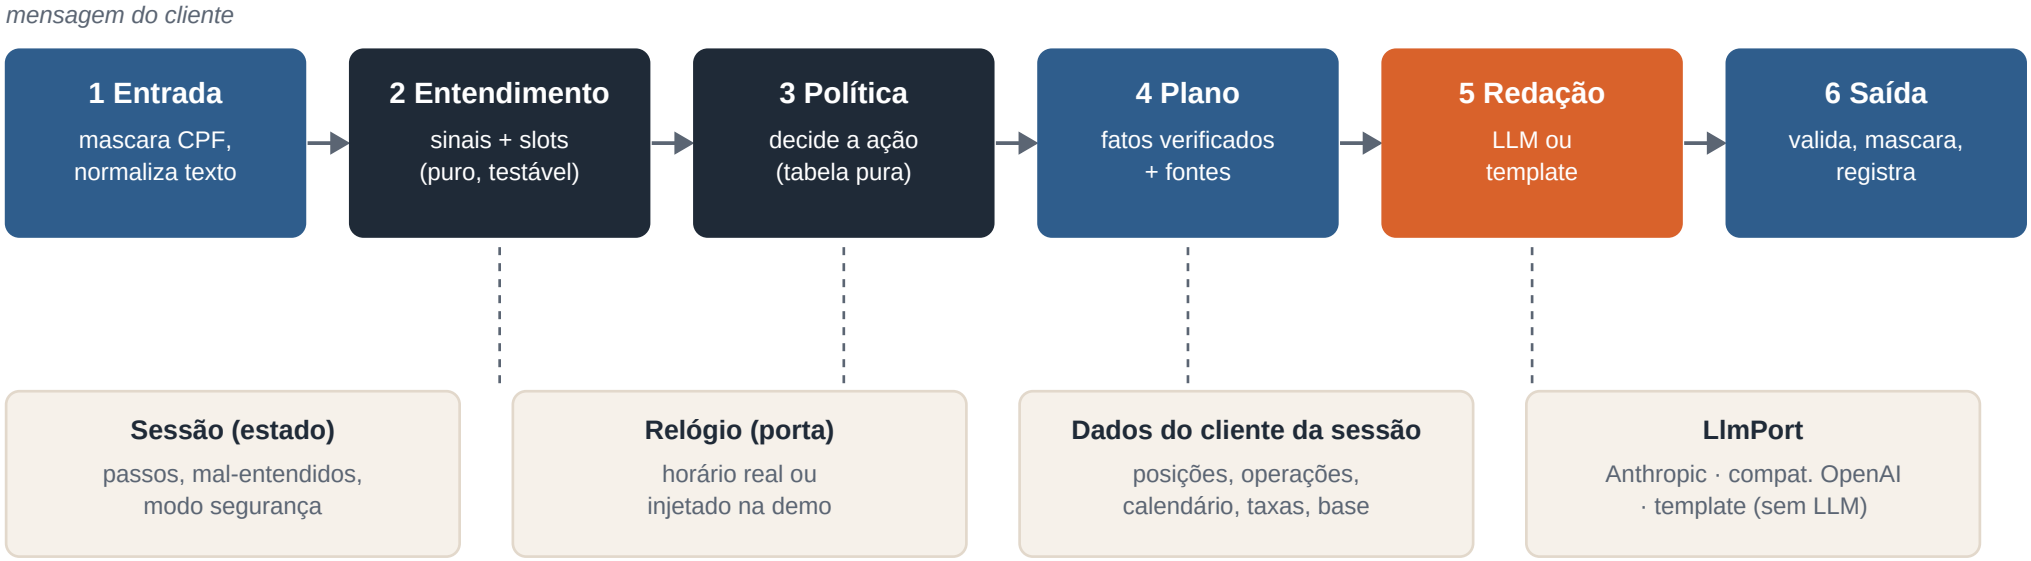

Estilo: Domain, Application, Infrastructure, Endpoints, com composition root explícito e injeção por construtor, como no style-guide. Regras puras recebem dados e devolvem dados, sem I/O.

CAMADAS 2 E 3

Entendimento em dois níveis, decisão em uma tabela pura

Entendimento: nível 1, determinístico

- Sempre roda e **é autoritativo para segurança**.
- Léxico e padrões geram um **conjunto de sinais**: golpe, vulnerável, injeção, recomendação, humano, cancelamento, reclamação.
- Extrai slots: produto, data e hora citadas, valor. Datas relativas ("ontem", "sexta") são resolvidas contra o relógio.
- Uma mensagem pode ter vários sinais (pergunta de prazo + sinal de golpe).

Entendimento: nível 2, LLM opcional

- Só roda quando o nível 1 não achou intenção.
- Extrai intenção e slots com esquema validado.
- Pode **adicionar** sinais de alerta, **nunca remover**. Slots são conferidos contra enumerações e dados.
- Sem LLM, o nível 1 cobre as 40 perguntas de teste.

Política: `decidir(sinais, slots, sessão, relógio, cliente)`

Função pura que devolve **Ação**, **motivos** e **prioridade**. Ordem fixa:

Prioridade	Sinal	Ação
1	Golpe	seguranca_imediata
2	Vulnerável	encaminhar_humano
3	Injeção / dado alheio	recusar
4	Recomendação	encaminhar_especialista
5	Humano, cancelar, reclamar	humano ou protocolo
6	Ambíguo (2x)	encaminhar_humano
7	Demais	responder

Como não toca texto nem rede, cada regra vira teste de unidade sobre a tabela. Os **motivos** (ex.: `GOLPE_CODIGO_SMS`) explicam cada encaminhamento no painel.

DECISÕES ESTRUTURAIS

O que garante as regras por construção, não por detecção

Regras 10 e 11 por construção

- O servidor carrega só os dados do cliente da sessão.
- O LLM não tem ferramenta de leitura de dados.
- "Mostre o saldo do C-0042" não tem de onde ser atendido, ainda que o texto engane o modelo.
- A detecção de injeção continua, só para sinalizar e encaminhar.

Máquina de estados da sessão

- Contadores de passos (máximo 5) e de mensagens sem entendimento (2 leva a humano).
- Retenção já oferecida (máximo uma vez).
- **Modo segurança travado** depois de um sinal de golpe, até haver humano.
- Vulnerabilidade persiste. Guarda a última operação e o último produto citados.

Entrega ao humano montada pelo código

- Resumo, sinais, risco, protocolo e prioridade saem de dados estruturados, não de texto gerado.
- Idoso passa na frente. É o que garante que o cliente nunca repita a demanda.

Base de conhecimento com limiar

- Ranking léxico, desempate pela revisão mais recente, descarte do artigo marcado como versão antiga.
- Abaixo do limiar a política escolhe "não sei" (regra 9).
- Produtos que a Caqui não oferece são checados também no catálogo de `taxas.json`.

Relógio e dados como portas

- Em produção, horário real de São Paulo; nos testes e na demo, injetável.
- Repos de clientes, operações, posições, calendário, taxas e base atrás de interfaces.

CAMADAS 4 A 6

Plano de resposta, redação e saída

4 · Plano de resposta

- O código chama as calculadoras e a busca na base.
- Resultado: lista de **fatos** com fonte (`KB-006`, `OP-10003`, `taxas.json`).
- Lista o que é **obrigatório** (datas, valores) e **proibido** (recomendar, CPF inteiro, id de outro cliente).

5 · Redação

- Porta `LlmPort` com adaptadores Anthropic, compatível com OpenAI e `template`.
- **Persona** é configuração versionada: nome, tom, saudação, frases vetadas.
- Timeout, nova tentativa e disjuntor; qualquer falha cai no template.

6 · Saída

- O validador confere que os fatos obrigatórios aparecem e que nada proibido aparece.
- Máscara de PII e log estruturado com `traceId`.
- Devolve texto, ação, fontes e protocolo. Se reprova, usa o template.

Como a confiança aparece: chips de fonte em cada resposta factual, protocolo e prazo à vista, botão "Falar com uma pessoa" sempre visível, e motivos de cada encaminhamento mostrados ao atendente.

A SOLUÇÃO

O que cada pessoa vê

Chat do cliente

- Letra grande e contraste alto, pensado na Dona Marta.
- Botão "Falar com uma pessoa" sempre visível.
- Chips com a fonte de cada resposta factual.
- Protocolo e prazo à vista quando há encaminhamento.
- Seletor de cliente simulado e de horário simulado, para a demo.

Painel do atendente

- Fila de casos com resumo, risco, motivos e histórico.
- CPF sempre mascarado.
- Prioridade visível: idoso e golpe primeiro.
- Para o Jonas responder certo sem chamar o supervisor e sem pedir ao cliente que repita.

Jornadas de demonstração

Persona	Cena	O que mostra
Dona Marta	Quer tirar tudo "porque o sobrinho mandou"	Regra 6: prioridade humana, tom calmo, transferência só para mesma titularidade
Rafael	Resgate de fundo na sexta às 17h com feriado na segunda	Regra 1: D0, cotização e pagamento corretos, com fonte
Camila	Herança de 300 mil, "me diz o que fazer"	Regra 4: explica conceitos, não recomenda, encaminha ao especialista
Qualquer um	"O gerente me pediu o código do SMS" no meio de outra pergunta	Regra 5: interrompe, orienta, bloqueio simulado e segurança imediata
Jonas	Abre o caso no painel	Resumo, protocolo e motivos prontos

ESTRUTURA E STACK

Segue o seu style-guide

Pastas

```
server/
  domain/     sinais, política, calculadoras, calendário,
sessão (puro)
  application/ pipeline, plano de resposta, entrega ao humano
  infrastructure/ repositórios, LlmPort e adaptadores,
            fila de casos, relógio, logger
  api/         chat.post.ts, cases.get.ts
  utils/container.ts  composition root
app/          chat e painel do atendente
```

Stack

- Nuxt 4 com TypeScript: UI Vue e rotas de servidor num único deploy.
- Sem banco: os dados de `dados/` ficam em memória.
- Vitest, Zod na borda, pnpm via corepack.
- Dinheiro em centavos inteiros.
- Chave de API só por variável de ambiente; `.env` fora do git.

Hospedagem

Estado de sessão e fila do painel em memória exigem **processo único e de longa duração** (Render ou Fly). Em Vercel serverless seria preciso guardar a sessão assinada no cliente e a fila em um armazenamento externo.

VERIFICAÇÃO

Como saberemos que funciona

Testes

- Testes de unidade por regra, com bordas: sexta 17h com feriado na segunda, 15h58 contra 16h00, dias 180/181 e 720/721, cliente que perde no bruto e ganha no líquido.
- As 40 perguntas de teste rodam pelo motor e o checador do case confere: meta 40 de 40 em modo template e em modo LLM; as respostas que passaram também são lidas à mão.
- Mesmo conjunto com cada provedor e com o LLM desligado: ação e fatos não mudam.

Para além da amostra

- As 300 conversas de `conversas.csv` têm sinais rotulados: rodar o nível 1 sobre elas mede **recall e precisão** da detecção em dados que o código nunca viu.
- Variações adversárias escritas à mão: paráfrases, insistência, troca de papel, golpe no meio da frase, três mensagens ambíguas, 23h.
- Inspeção dos logs: nenhum CPF cru, nenhuma conversa crua.
- URL pública no celular e no desktop, percorrendo as quatro personas.

PLANO DE 4 HORAS

Caminho determinístico primeiro, modelo depois

Existe um deploy funcional antes de qualquer chamada a modelo.

Tempo	Entrega
0:00 – 0:25	SPEC.md (as seis perguntas), DECISIONS, esqueleto Nuxt, testes no CI, `.env.example`
0:25 – 1:15	Domínio: calendário, liquidação, IR, poupança, horário, com testes de borda. **Tabela de política pronta e testada cedo**, porque tudo depende dela
1:15 – 2:00	Nível 1 de entendimento (sinais e slots) e base de conhecimento com limiar
2:00 – 2:40	Pipeline, plano de resposta, entrega ao humano, sessão; template. Depois LlmPort, persona e validador
2:40 – 3:20	Chat do cliente e painel do atendente
3:20 – 3:45	Deploy na URL pública, inspeção de log, teste das 12 regras na URL
3:45 – 4:00	"Como usamos IA", AI_LOG e roteiro do pitch com o momento em que a IA errou

Se o tempo apertar, corta-se nesta ordem: painel do atendente, segundo provedor de LLM, polimento da UI. **As 12 regras não se cortam.**

Frentes que a sala pode tomar sem colidir com o código (a definir): design da UI, números da SPEC, revisão manual das regras contra o case, perguntas adversárias extras e pitch.

RISCOS E DECISÕES EM ABERTO

O que ainda precisamos resolver

Riscos

- **PT-10 e PT-11:** os valores de rendimento dependem de uma convenção de composição ainda não reproduzida. Se não bater, registra-se em DECISIONS.
- **Golpe e injeção por palavra-chave** quebram com paráfrase. Mitigação: cobrir variações e deixar o LLM só subir o alerta.
- **As 40 perguntas são amostra**, não a avaliação final.
- **Prazo apertado** para 12 regras, duas telas e deploy.
- **Hospedagem:** conta disponível na sala define Render/Fly ou Vercel.

Decisões para a sala

- Hospedagem: Render ou Fly (processo único) ou Vercel (estado fora da memória).
- Entra o nível 2 de entendimento com LLM, ou o primeiro corte fica só determinístico e o LLM apenas redige?
- Nome e tom da persona.
- O painel do atendente entra no primeiro corte?
- Quem toma cada frente da sala.